AI論文新聞

2026年10月29日（木）　arXiv 新着 cs.AI / LG / CL / CV ほか より選定　編集：Claude

一面　AI×科学発見

「物理法則が違う世界」でAIは法則を見抜けるか 12モデル中、発見できたのは1つだけ

重い物ほどゆっくり落ちる世界を作って、何も教えずに放り込む――「自分で問いを立てる力」を測る新しい試験

原題：Can LLMs Uncover Hidden Physical Laws through Free Exploration?（arXiv 2610.37649 / cs.CL）

AIが科学者になれるのか。これまでの評価の多くは「この現象の法則を求めよ」と問題を与える形式で、いわば“出題された試験”だった。しかし実際の科学的発見は、誰も問題を出してくれない状況で「あれ、おかしいぞ」と気づくところから始まる。本研究はまさにこの**「気づく力」**を測ろうとしている。

どうやって試すのか

研究チームは **LongChang** という自動フレームワークを作った。これは物理シミュレーションの世界を生成するが、その中では1つ以上の物理法則がこっそり書き換えられている。たとえば「重い物体ほど遅く落ちる」といった具合だ。

評価対象のLLMは“探検家”としてこの世界に入り、物体を動かしたり道具を自作したりして自由に実験する。**何を調べよ、という課題もヒントも一切ない。**探検後に報告書を書き、別のLLMエージェント群が「法則を正しく言い当てたか」「実験で裏づけられているか」を採点する。採点役は書き換えられた法則の正解と探検記録の両方を見ている。

さらに探検記録をもとに次の場面（シーン）が自動で進化していくため、人間が介在しなくても「場面生成→探検→採点→次の場面」のサイクルが回り続ける。

結果は厳しい

12のLLMを試した結果、法則の発見に成功したのは **GPT-6-Astra の16.7%のみ**。残り11モデルはすべて**0%**だった。探検記録を読むと、モデルは異常な現象に出くわしても深追いせずに素通りしていたり、法則を部分的にしか特定できていなかったりした。

📌 ここがポイント

問題を「解く」力と、問題を「見つける」力は別物。今のLLMは前者は得意でも、後者はまだほぼできていない――という現状を数字で示した点に価値がある。

解説：なぜ重要か

「AIに研究させる」構想が各社で進む中、ボトルネックはどこかを示している。計算や文献整理ではなく、**違和感に気づいて仮説を立てる段階**が最も弱い。逆に言えば、この指標が伸び始めたときがAI科学者の本当の転換点になりうる。

ただし注意点もある。採点もLLMが行っているため、評価そのものの信頼性は今後の検証が必要だ。また16.7%という数字は1モデルだけの成績で、「できるモデルが出始めた」と読むか「まだほぼ無理」と読むかは、見方が分かれるところだろう。

注目度 ★★★★★

AI安全

“注意”の向け先を制御してプロンプト注入を防ぐ

攻撃成功率 97% → 10%。性能を落とさない新しい防御「Heads of Security」

原題：Heads of Security: Learned Attention Gates Improve Prompt Injection Robustness（2610.37657 / cs.LG）

用語メモ：プロンプトインジェクション
AIに読ませるWebページやメールの中に「前の指示を無視して〇〇せよ」と仕込み、AIを乗っ取る攻撃。AIエージェントが外部の情報を読むほど危険が増す。

根本的な問題は、LLMにとって「ユーザーの命令」と「読んでいる資料の中身」がどちらも同じ文字の並びに見えてしまうことにある。本研究は、この**「命令とデータの分離」**をモデルの内部構造で実現しようとした。

仕組み

Transformer は多数の“注意ヘッド”を持ち、それぞれが文中のどこに注目するかを決めている。HoS はヘッドごとに小さな**ゲート（弁）**を学習させ、信頼できるトークン（ユーザーの指示）と信頼できないトークン（外部資料）の間で、注意の配分を調整する。資料の内容は理解できるが、そこに書かれた命令には従わない、という状態を狙っている。モデル全体を作り直さず、小さな部品の追加で済むのも利点だ。

成果

Llama-3.3-70B と GPT-OSS-20B で検証した。ブラックボックス攻撃 RL-Hammer の成功率は、無防備な GPT-OSS-20B で97%、既存の最有力防御 SecAlign でも85%だったが、**HoS では10%**に下がった。強力なホワイトボックス攻撃でも、同じ成功率に達するのに3倍の計算量が必要になった。

重要なのは**普段の性能を落とさない**点だ。SecAlign や同種の構造的防御 ASIDE は、少数例を示すプロンプト（few-shot）で性能が落ち、ASIDE はツール使用の性能が10%まで下がった。HoS はベースモデルの性能を保っている。

解説

「安全にすると賢さが落ちる」というトレードオフを、狙いを絞った小さな介入で緩和できることを示した。AIエージェントに受信メールや社内文書を扱わせたい人には、実用上かなり意味のある方向性だ。

注目度 ★★★★☆

モデル公開

文字も画像も音も動画も「同じ地図」にEmbeddingGemma 2

2〜12倍大きいモデルを上回るオープン埋め込みモデル

原題：EmbeddingGemma 2: Unified and Efficient Multimodal Representations（2610.37364 / cs.LG）

> **用語メモ：埋め込み（Embedding）**
> 文章や画像を数百〜数千個の数字の並び（ベクトル）に変換すること。意味が近いものは近い位置に置かれるため、検索・推薦・RAG（AIに資料を引かせる仕組み）の土台になる。

Google の Gemma 系列から、テキスト・画像・音声・動画、さらにそれらの組み合わせを**1つの共通空間**で表現できるオープンモデルが公開された。「この写真に合う音楽」「この会話音声に関係する資料」のように、種類の違うデータどうしを直接比べて検索できる。

工夫

①簡素化した per-layer embeddings（層ごとの埋め込み）の導入、②扱うモダリティと学習目標を段階的に広げていく多段階カリキュラム。いきなり全部を混ぜて学ばせず、順番に難しくしていくことで、単一モダリティでも混合モダリティでも品質を保っている。

軽さへの配慮

必要なエンコーダだけ読み込む（画像を使わないなら画像部分を省く）、画像のトークン数を調整する、ベクトルの次元を切り詰める、量子化した重みを使う――といった選択肢がある。ノートPCやエッジ機器でも使いやすい。

解説

これまでマルチモーダル検索は、モダリティごとに別のモデルを組み合わせるのが普通だった。高性能なものが1つのオープンモデルで手に入るのは、個人開発や社内検索の構築にとって大きい。

注目度 ★★★★☆

AIエージェント

ツールを使うAIの「スケーリング則」を発見

849モデルを訓練してわかった、増やすべきは「問題数」より「道具の種類」

原題：Scaling Laws for Tool-Use Agents via Controllable Environment Synthesis（2610.37648 / cs.LG）

> **用語メモ：スケーリング則**
> 「データや計算量をこれだけ増やせば性能がこれだけ上がる」という経験則。これがわかれば、どこに予算を使うべきか事前に計画できる。

検索・予約・データベース操作などの“道具”を使いこなして多段階の仕事をこなすAIエージェントの訓練には、大量の練習環境が要る。本研究は練習環境を人工的に生成する SynthAPI を作り、**道具・課題・道具が操作するデータベース**の3つの多様性を個別に調整できるようにした。

45万8752件の課題、4つのサイズの計849モデルという大規模な実験で、環境の規模と構成から汎化性能を予測できる法則を導いた。

得られた教訓

データ予算が大きくなるほど、**課題の数を増やすより、道具とデータベースの種類を増やすほうが効く**。また、データを複雑にするほど伸びが大きい。この法則に従って作ったデータで訓練したエージェントは、既存の大規模データで訓練したものを4つのベンチマークで上回った。

解説

人間の学習に例えると「同じ型の問題を大量に解くより、いろいろな道具と状況に触れたほうが応用力がつく」ということ。直感的だが、それを数式で予測できる形にしたのが本研究の価値だ。

注目度 ★★★★☆

ロボット

ロボット制御の論争に終止符？ 「ただの行動モデル」JAM

未来の画像を“描かずに”予測させるだけで性能向上、学習計算量は73%減

原題：Vision-Language-Action or World-Action? Just Action Models（2610.37219 / cs.CV）

ロボットの脳をどう作るかで、二つの陣営が対立している。言語と画像を学んだモデルを土台にする **VLA** 派と、動画生成モデルのような「世界がどう動くか」を学んだモデルを土台にする **WAM** 派だ。

著者らは、この論争が実は3つの独立した選択を混同していると指摘した。①土台にするモデル、②未来の観測をどう学習目標にするか、③その仕組みを本番の推論時にも残すか、である。両者の性能差がどれによるものかは、これらを切り分けないとわからない。

JAM の発想

好きな視覚モデルを土台に「行動を出す部品」をつけ、**行動の誤差**と**予見（foresight）の誤差**の2つで学習する。予見の誤差は「今の画像から、未来の画像の特徴量を当てる」というもので、未来の画像そのものを生成する必要はない。予測用の部品は学習後に捨てるので、**推論時のコストは増えない。**

結果

LIBERO 系ベンチマークで、比較対象の FastWAM（97.0% / 55.3% / 91.2%）を上回る 98.2% / 64.5% / 91.4% を達成した。特に難しい LIBERO-Plus で約9ポイント伸びている。予見の目標をキャッシュすれば、学習計算量は約73%減る。

解説

「未来を想像する力は役立つが、絵として描く必要はない」という結論。どちらの陣営の土台でも効くため、論争を“統合”する形になっている。

注目度 ★★★☆☆

セキュリティ

AIの「無断コピー」を見抜く新技術

蒸留されたモデルに残る“透かしの盆地”を、APIを叩くだけで検出

原題：Watermark Basins: Black-Box Detection of Distilled LLMs（2610.37266 / cs.CR）

> **用語メモ：蒸留（distillation）**
> 高性能なAI（先生）の出力を大量に集め、それを手本に別のAI（生徒）を訓練する手法。他社のAPIで無断に行われると、知的財産の盗用になりうる。

AI企業は、自社モデルの出力に目に見えない**透かし（ウォーターマーク）**を入れておき、怪しいモデルの出力にその痕跡が残っていないかを調べる。だが従来の「単語の出方の偏り」を見る方法は、蒸留時

の出力がランダム性の低い設定（低温度）で作られていると検出しにくかった。

新発見「透かしの盆地」

透かし入りの出力で学習すると、モデルのパラメータ空間に、透かしの鍵に固有の“くぼみ”のような痕跡が刻まれる。しかもそれは通常の学習で変化する方向とは**直交**している（＝混ざらない別方向にある）。

検出器 WM-Basin は、疑わしいモデルの API 出力を、手元の別モデルで勾配（どの方向に学習が進むか）に変換する。そこから通常の学習方向を取り除き、残りが透かしの盆地と揃っているかを調べる。相手の重みや内部の数値は不要だ。

成果

誤検出率0.1%という厳しい条件で、検出率は**79%**（従来法29%）。より難しい設定でも45%（従来法1.3%）だった。痕跡は量子化・枝刈り・強化学習での追加学習を経ても残る。

解説

モデル蒸留をめぐる企業間の争いは現実の問題になっている。法的な証拠として使えるほどの信頼性があるかは今後の議論だが、「出力だけで盗用を立証する」道具としては大きな前進だ。

注目度 ★★★★☆

各記事は arXiv の論文概要をもとに Claude が解説したものです。「解説」欄は編集側の見解を含みます。詳細は arxiv.org/abs/（ID）で原文を参照してください。