論文ダイジェスト 2026-10-29

出典: arXiv 新着（Claude が選定） / 要約: Claude

今日のハイライト

Google の Gemma 系から、テキスト・画像・音声・動画を1つの空間で扱えるオープン埋め込みモデルが登場しました。マルチモーダル検索やRAGの基盤が、小型・オープンで手に入る流れが加速しています。

1. EmbeddingGemma 2：統一的で効率的なマルチモーダル表現

原題: EmbeddingGemma 2: Unified and Efficient Multimodal Representations / **arXiv**: 2610.37364 / **分野**: cs.LG

- **一言で**: テキスト・画像・音声・動画とその組み合わせを、1つのベクトル空間に埋め込めるオープンモデル。
- **何をした**: 簡素化した per-layer embeddings を導入し、扱うモダリティと学習目的を段階的に広げる多段階カリキュラムで学習しました。これにより、単一モダリティ、モダリティ間、混合モダリティのいずれの評価でも高い品質を保っています。全モダリティの埋め込みベンチマークで新たなパレートフロンティアを達成し、特化型モデルや2〜12倍大きいモデルを上回りました。
- **なぜ凄い**: 1モデルで「画像で音声を検索」のような横断検索ができ、しかも公開されています。必要なエンコーダだけの読み込み、画像トークン数の調整、次元の切り詰め、量子化に対応しているので、手元のPCやエッジ機器でも動かしやすい設計です。
- **注目度**: ★★★★★